Blindaje Financiero: Detección Inteligente de Fraude.

Análisis de patrones de riesgo para plataformas Fintech.

Pablo A. Martinez

Contexto:

Los sistemas de prevención estáticos ya no son suficientes. El fraude financiero evoluciona rápidamente, causando pérdidas millonarias y dañando la reputación de las empresas.

Audiencia:

Este informe está dirigido al Directorio de Riesgos (CRO) y equipos de Seguridad Informática. Busca proveer evidencia basada en datos para ajustar las políticas de bloqueo automático.

Preguntas e Hipótesis

- ¿El monto de la transacción es el factor más importante para detectar un fraude?
- ¿Las transacciones fraudulentas ocurren a una velocidad inusual en comparación a un usuario normal?
- ¿Qué tan relevante es la ubicación geográfica y el dispositivo utilizado?

Resumen Metadata

- Origen: Datos extraídos de logs transaccionales históricos.
- Muestra Analizada: Se aplicó una técnica de Under-sampling aislando 4000 registros críticos (50% fraude, 50% legítimo) para un análisis sin sesgos estadísticos.
- Enriquecimiento: Se conectó el pipeline a la API pública de ExchangeRate para estandarizar los valores monetarios a moneda local, permitiendo un análisis financiero real.

Mapa de Calor - La Complejidad del Fraude

- Insight: El análisis de correlación lineal (Pearson) revela valores bajos entre el fraude y variables individuales como la velocidad o el monto.
- Conclusión de Negocio: Esto demuestra que el fraude no sigue reglas lineales simples (ej. "a mayor monto, mayor riesgo"). Para detectarlo, las reglas estáticas fallarán; necesitamos modelos de Machine Learning que entiendan combinaciones no lineales y umbrales de comportamiento.

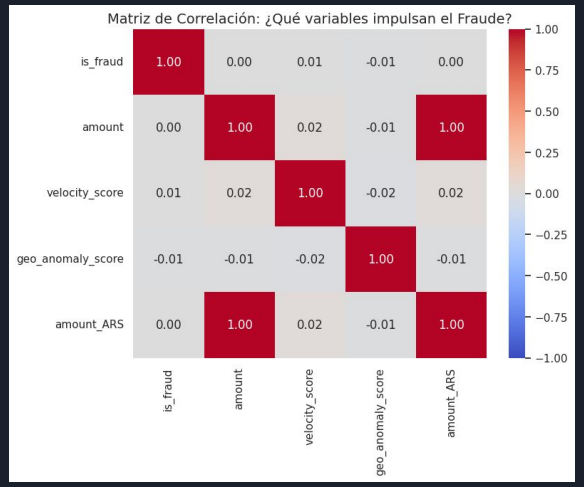

Análisis de Densidad: La Complejidad del Patrón.

- Observación: "El gráfico KDE muestra un solapamiento significativo en las distribuciones de velocidad y monto entre ambas clases."

- Insight Ejecutivo: "Esto confirma que los defraudadores imitan casi a la perfección el comportamiento del usuario legítimo. La detección no puede basarse en una sola variable (regla simple), sino en la interacción combinada de múltiples factores que solo un modelo de Machine Learning puede procesar."

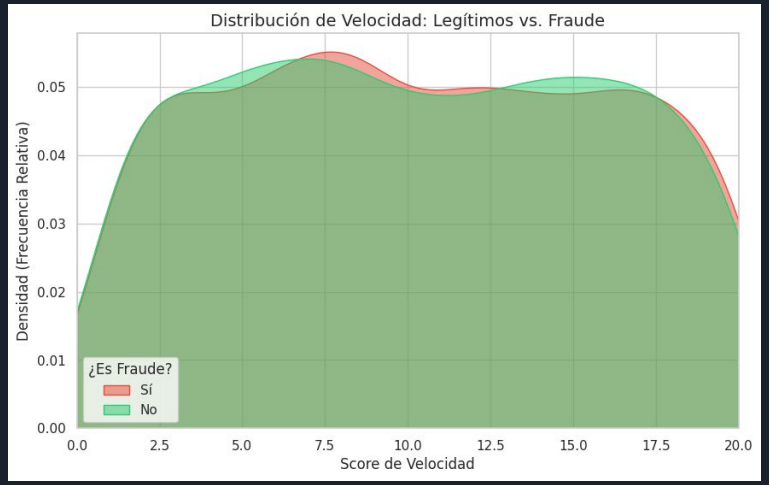

Velocidad vs. Monto

Las transacciones legítimas se agrupan en velocidades bajas. El fraude opera en "ráfagas" (alta velocidad), independientemente de si el monto es grande o pequeño.

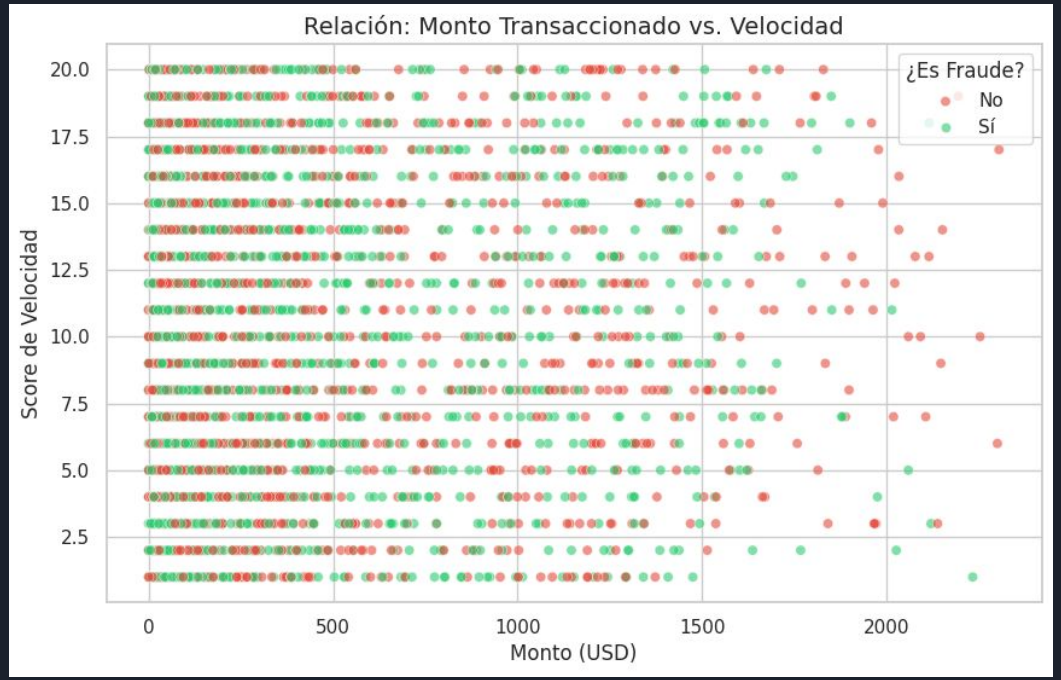

Anomalía Geográfica y Dispositivos

El fraude presenta niveles de anomalía geográfica consistentemente más altos. Esto es especialmente crítico cuando las transacciones provienen de dispositivos móviles o webs no habituales."El análisis revela que en transacciones digitales (Mobile y Web), el fraude presenta niveles de anomalía geográfica significativamente más altos y una mayor dispersión. En contraste, en puntos físicos (ATM/POS), el comportamiento geográfico es más uniforme, lo que sugiere que el riesgo digital requiere políticas de validación de ubicación más estrictas."

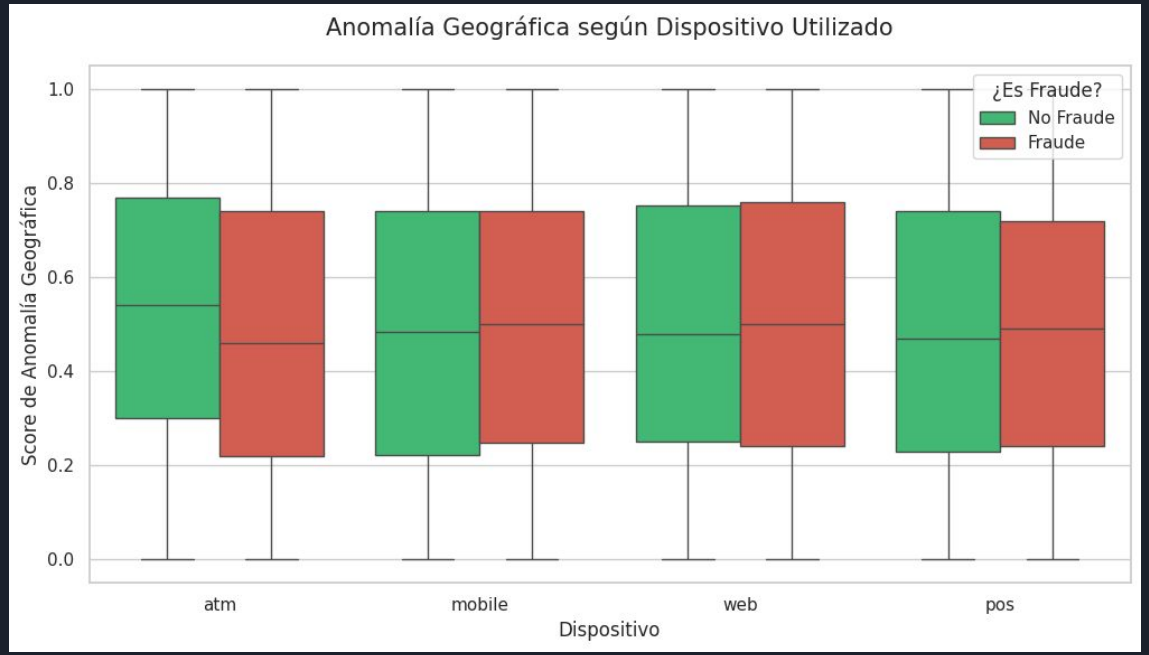

Insights (Hallazgos Principales)

- **Monto como distractor: El análisis confirma que el monto no define el riesgo por sí solo. El fraude se fragmenta en operaciones de diversos tamaños para evadir umbrales de seguridad tradicionales.**

- **Límites de la Velocidad: El fraude moderno ha evolucionado para imitar el ritmo del usuario (solapamiento en la densidad), lo que invalida las reglas de velocidad fija y exige un análisis de patrones más complejo.**

- **Predicción Geográfica: La anomalía de ubicación se consolida como el predictor más robusto, principalmente en dispositivos Mobile y Web, donde la huella geográfica del atacante es más difícil de ocultar.**

Recomendaciones (Business Action)

- Priorizar Canales Digitales: Implementar validación de identidad reforzada (Step-up Authentication) basándose en el geo_anomaly_score en Web y Mobile.

- Abandono de Reglas Estáticas: Dejar de depender de "Montos Máximos" y pasar a un modelo de Scoring que pondere la geografía y la velocidad de forma combinada.

- Detección de Anomalías No Lineales: Dado que las variables se solapan (KDE), se recomienda avanzar hacia modelos de Random Forest o XGBoost para capturar las interacciones que el análisis lineal no muestra.